

탐지 계층 R&D 보고서 — 범용 1차 탐지 모듈 구축·통합

작성일: 2026-07-16 · 검증 환경: macOS Apple Silicon(M4 Max, MPS) · Python 3.12 / torch 2.12.1 / transformers 5.13.0

1. 수행기간

2026-07-08 ~ 2026-07-16 (9일) — 전 과정 로컬 완결 (클라우드·GPU 비용 0). 선행 R&D(BERT·NER·YOLO·PII·OpenCV, 07-05~08) 위에서 진행.

일자	수행 내용
07-08	학습 데이터 산출물 환경 (범용 학습기·규약·3종 세트)
07-09	분류 잘하는 법 (Rule vs BERT vs 하이브리드)
07-10	CLIP 상황 판단 / 통합 UXUI 데모
07-12	검수·라벨링·이미지 검색 탭 확장, 프롬프트 카탈로그 정비
07-13	YOLO 직접 라벨링→학습, 보고 패키지 통합
07-14~16	OCR 추출 계층 — Easy-Paddle 동일 잣대 비교, OpenCV 전처리 복구, OCR→탐지 파이프라인, 두 엔진 교차 검증

2. 목표 및 목적

- **목표:** 플랫폼의 1차 탐지 계층(텍스트 분류·PII·NER·이미지 탐지·상황 판단)과 그 앞단 추출 계층(OCR: 이미지→텍스트)을 공개 데이터로 로컬에서 end-to-end 재현하고, 하나의 데모로 통합한다.
- **목적:** 특정 도메인이 아니라 **도메인 교체 가능한 범용 계층**을 확보 — 아동·청소년 성착취물 대응, 불법스포츠포도박 등 복수 적용처에 데이터·프롬프트·룰셋만 바꿔 이식. 실전 데이터 확보 전에 파이프라인·방법론·판단 기준을 근거와 함께 확정해 시행착오 비용을 제거.

3. Why · How · What

Why (왜 필요한가)

- 탐지 대상 도메인은 여럿이고 계속 늘어난다. 도메인마다 코드를 새로 짜면 반복 비용이 누적 → 규약(계약) 위에서 코드는 고정, 데이터·설정만 교체하는 구조가 필요.

- 좋은 분류가 무엇인지, 어떤 방법을 언제 쓰는지가 근거 없이 정해지면 실전에서 흔들린다 → 동일 잣대 비교로 방법 선택 기준을 확정.

How (어떻게 검증했나)

- 고정 test셋 + 산출물 3종 세트 규약 + MLflow 기록으로 **동일 잣대 비교** 인프라 구축.
- 테스트 누출 금지 3단(train으로 제작 / validation으로 조정 / test로 채점만)을 전 실험에 적용.
- 각 모듈을 미니 데이터로 완주 → 통합 데모로 조립 → 사용자 검증.

What (무엇을 얻었나)

- 6개 1차 탐지 모듈 + 이를 조립한 데모(탭 4개) + 도메인 무관 판단 기준(가이드).
- 분류·CLIP·YOLO의 실측 성과와, "단일 승자 없음 → 업무 요구로 선택"이라는 방법론.

4. 수행 과정

전체 아키텍처·모듈별 구조·데이터 순환 도식은 [5. 도식도] 참조. 모듈별 수행 요지:

- **학습 데이터 산출물 환경**: text, label CSV만 주면 열·클래스 자동 인식 → 학습 → 산출물 3종 세트(가중치+label_map+meta). 데이터셋(정본) → 학습 → 재사용 → 검수 → 편입의 순환 확립.
- **분류 방법 비교**: 같은 스팸 test셋 300건에서 RULE·BERT·하이브리드 동일 잣대 비교. 오답 교집합 분석으로 양상불 근거 도출.
- **CLIP 상황 판단**: zero-shot → linear probe → KoCLIP 3단계. 프롬프트가 곧 분류 체계임을 실증 (재학습 없이 교체).
- **통합 UXUI**: 완료 모듈 5개를 신규 학습 0으로 Gradio 탭 4개에 통합. 검수·라벨링 탭으로 데이터 순환을 UI로 폐쇄.
- **직접 라벨링**: labelme(로컬 도구)로 직접 라벨링 → YOLO 규약 변환 → 전이학습 → 탐지 실증.
- **OCR 추출 계층**: 정답 아는 문장을 렌더링(완벽 조건+열화 4종)해 CER(문자 오류율) 동일 잣대로 EasyPaddle 비교 → OpenCV 전처리 복구 실증 → OCR 텍스트를 분류·NER·PII에 인계하는 파이프 라인 실증 → 두 엔진 교차 검증(불일치만 검수).

5. 수행 결과 (성과 지표)

분류 (고정 test 300건)

방법	정확도	스팸P	스팸R	F1
RULE	0.900	0.948	0.848	0.895
BERT-full	0.953	0.993	0.914	0.952

방법	정확도	스팸P	스팸R	F1
HYBRID-AND	0.913	1.000	0.828	0.906
HYBRID-OR	0.940	0.946	0.934	0.940

CLIP (고정 test 27장): 부정형 프롬프트 0.444 / 긍정형 0.778 / **KoCLIP+한국어 0.852(최고)** / 영어모델 +한국어 0.519(붕괴).

YOLO 직접 라벨링: 웹캠 16장 라벨링→학습 → 검증 mAP50 **0.995**, 데모 탐지 확인. 확장 실험 (COCO+신규클래스 병합): 신규 클래스 습득했으나 COCO 붕괴(0.177) — **파국적 망각** 실증.

OCR (CER 문자 오류율 — 낮을수록 좋음): 완벽 조건 한국어 **Paddle 4.8%** / **Easy 9.5%**. 기울기 보정 (deskew)이 회전 열화 완전 복구(64.3→9.5%, 엔진 무관) — **deskew+Paddle 2.4% 최고**. 반면 확대 전처리 유해(9.5→11.9%, 유령 글자). 파이프라인 실증: 한 글자 오독(010→0/0)에 PII 탐지 전멸(4건→0건, 위험도 MEDIUM→INFO) — ②**추출 품질**=③**탐지 성능**. 두 엔진 교차 검증(불일치만 검수): 같은 오답에 합의한 사례 0(맹점 0), 실사에서 신뢰도 0.89 유령 텍스트 포획.

판독

- 분류는 **단일 승자 없음** — 오탐 교집합 0(완전 상보)이라 AND에서 오탐 전멸(P 1.0), OR에서 미탐 최소. 업무의 치명적 실수로 방법을 고른다.
- CLIP은 프롬프트 설계가 성능을 좌우(하이퍼파라미터) — 후보 목록 = 탐지 범위의 정본.
- 소데이터 병합 재학습은 파국적 망각 위험 → **범용+특화 모델 병행 운용**이 실무 정답.
- OCR도 단일 승자 없음(정확도 Paddle vs 속도 Easy 5~10배) — 오독 방어선 3층(전처리·신뢰도 검수 라우팅·엔진 교차 검증)으로 관리. 형식 기반 과제(PII)가 오독에 가장 취약하고 실패가 조용함.

6. 기대 효과

1. **도메인 즉시 이식:** 새 도메인은 데이터·프롬프트·룰셋만 교체 — 코드 재작성 없이 탐지 계층 재사용.
2. **방법 선택의 근거화:** 오탐/미탐 중 무엇이 치명적인지로 방법(단일·하이브리드)을 고르는 기준 확정.
3. **데이터 자산 순환:** 검수 UI로 모델 판정을 라벨 자산으로 승격 — 쓸수록 기준이 성장.
4. **비용 효율·재현성:** 전 과정 로컬, MLflow 기록으로 재현 가능. 상사 보고 패키지(문서+코드+가중치) 완비.

7. 산출물

구분	내용
모듈 코드	텍스트 학습기·RULE·NER·YOLO·CLIP·PII· OCR (rnd-* 폴더)
통합 데모	app.py (Gradio 탭 4개) — 진입점
가중치	ko-spam-full-ner_klue-yolov8n (패키지 포함, 각 ~420MB)
문서	1 연구문서·2 소스코드·3 사용법·4 가이드·5 도식도·6 보고서(본 문서)
환경	통합 requirements.txt (13개 고정) · README (맥·윈도우)

8. 향후계획

1. **실전 도메인 데이터 적용** (핵심 병목): 도메인 라벨·이미지 확보 시 동일 파이프라인으로 즉시 이식 — 룰 키워드 재선정·CLIP 프롬프트 재확정.
2. **OCR 실전 파일럿**: 도메인 이미지(문서형 캡처)로 처리 시간·텍스트 포함률·엔진 불일치율 계수 실측 — 신뢰도 검수 문턱 확정(현재 수치는 합성·장면 텍스트 기준).
3. **검수 자산 축적 → 재학습**: 데모 검수 탭으로 도메인 라벨을 모아 고정 test셋 위에서 성능 개선 추적.
4. **후속 계층 연동**: 1차 탐지 결과를 Hybrid RAG(근거 검색)·Graph RAG(관계 분석)로 이어 붙이는 상위 파이프라인.